UNIVERSIDAD NACIONAL DE INGENIERÍA

UNIDAD DE POSTGRADO FACULTAD DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS ESCUELA DE POSGRADO

PLAN DE TESIS

"SISTEMA DE INSPECCIÓN FORENSE DE RAJADURAS EN ESTRUCTURAS DE CONCRETO BASADO EN YOLO11 CON CUANTIFICACIÓN GEOMÉTRICA E INCERTIDUMBRE CALIBRADA"

PARA OBTENER EL GRADO ACADÉMICO DE MAESTRO EN CIENCIAS CON MENCIÓN EN INTELIGENCIA ARTIFICIAL

ELABORADA POR:

ING. RAQUEL MEDIANERO HUARI

ASESOR:

MG. ENG. MARIA F. TEJADA BEGAZO

LIMA, PERÚ

2026

DATOS GENERALES

1. Título del plan de tesis

SISTEMA DE INSPECCIÓN FORENSE DE RAJADURAS EN ESTRUCTURAS DE CONCRETO BASADO EN YOLO11 CON CUANTIFICACIÓN GEOMÉTRICA E INCERTIDUMBRE CALIBRADA

2. Nombre del autor

ING. RAQUEL MEDIANERO HUARI

3. Nombre del asesor

MG. ENG. MARIA F. TEJADA BEGAZO

4. Área involucrada

UNIDAD DE POSTGRADO, FACULTAD DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS(FIIS)

MAESTRÍA EN CIENCIAS CON MENCIÓN EN INTELIGENCIA ARTIFICIAL

5. Lugar o institución donde se desarrolla el proyecto

UNIVERSIDAD NACIONAL DE INGENIERÍA, LIMA, PERÚ

6. Duración estimada del proyecto en meses

LA DURACIÓN ES DE 10 MESES
Fecha de inicio: abril 2026
Fecha de culminación: enero de 2027

INTRODUCCIÓN

La inspección de rajaduras en estructuras de concreto es una tarea de alto valor técnico y de alta carga subjetiva: el ancho, la longitud, la orientación y el patrón de agrietamiento sustentan el diagnóstico de una patología y, en un contexto forense, constituyen evidencia que debe ser trazable y reproducible. La visión por computador ha mostrado que es posible detectar y segmentar grietas a nivel de píxel [1,2], y la familia de detectores YOLO ofrece el compromiso entre velocidad y precisión que exige una inspección en campo [3,4]. Sin embargo, los estudios revisados no son comparables entre sí, la evidencia revisada por pares sobre YOLO11 aplicada a grietas es reciente y escasa, y la medición del ancho se reporta sobre todo en píxeles y sin una estimación explícita de incertidumbre [5–7].

Este plan propone desarrollar y validar un sistema de inspección forense de rajaduras en superficies de concreto que combina segmentación de instancias con YOLO11, cuantificación geométrica de longitud y ancho con calibración física, y predicción conforme para acompañar cada medida con un intervalo de cobertura verificable [8]. La evaluación utilizará el conjunto CCSS-DATA [9], que reúne 670 imágenes de grietas en concreto capturadas con cuatro cámaras distintas, lo que permite medir de manera explícita la pérdida de desempeño al cambiar de dispositivo. YOLOv8-seg actuará como línea base y se aplicará un protocolo con particiones fijas, semillas múltiples y pruebas estadísticas, de modo que los resultados sean comparables y reproducibles.

El documento sigue la estructura de la Escuela de Posgrado de la FIIS-UNI: el Capítulo 1 plantea y justifica el problema; el Capítulo 2 define los objetivos; el Capítulo 3 presenta las bases teóricas, las hipótesis y las variables; el Capítulo 4 describe el diseño metodológico; el Capítulo 5 desarrolla el cronograma y el presupuesto; y los anexos incluyen la matriz de consistencia y el estado del arte ampliado, con 65 papers.

ÍNDICE

INTRODUCCIÓN II

1. Planteamiento del problema 1
1.1. Planteamiento del problema . . . 1
1.1.1. Identificación y descripción del problema de estudio . . . 1
1.1.2. Antecedentes de la investigación . . . 1
1.1.3. Formulación del problema . . . 2
1.2. Justificación y alcances . . . 2
1.2.1. Justificación . . . 2
1.2.2. Alcances . . . 3

2. Objetivos 4
2.1. Objetivo general . . . 4
2.2. Objetivos específicos . . . 4

3. Marco teórico 5
3.1. Bases teóricas . . . 5
3.1.1. Rajaduras y patologías del concreto . . . 5
3.1.2. YOLO y segmentación de instancias . . . 5
3.1.3. Cuantificación geométrica de la máscara . . . 5
3.1.4. Incertidumbre y predicción conforme . . . 5
3.1.5. Generalización entre dominios y explicabilidad . . . 6
3.1.6. Métricas de evaluación . . . 6
3.2. Definición de términos . . . 6
3.3. Hipótesis y variables . . . 7
3.3.1. Hipótesis general . . . 7
3.3.2. Variables de la investigación . . . 7

4. Diseño metodológico 8
4.1. Tipo de investigación . . . 8
4.2. Nivel de investigación . . . 8
4.3. Métodos de trabajo . . . 8
4.4. Población y muestra . . . 8
4.4.1. Población . . . 8
4.4.2. Muestra . . . 8
4.5. Tipo de diseño . . . 9
4.6. Técnicas e instrumentos de recolección de datos . . . 9
4.7. Técnicas e instrumentos de análisis y procesamiento de datos . . . 9

4.8. Etapas de intervención del estudio 9
4.9. Justificación de la metodología 10

5. Administración del plan de tesis **11**
5.1. Cronograma 11
5.2. Presupuesto 11
5.2.1. Bienes 11
5.2.2. Servicios 12
5.3. Financiamiento 12
5.3.1. Consideraciones finales 12

REFERENCIAS BIBLIOGRÁFICAS **13**

ANEXOS **17**
Anexo A. Matriz de consistencia 17
Anexo B. Estado del arte ampliado 18

CAPÍTULO 1: PLANTEAMIENTO DEL PROBLEMA

1.1 Planteamiento del problema

El monitoreo de la salud estructural (SHM, por sus siglas en inglés) es un pilar crítico en el mantenimiento de infraestructuras de concreto armado. En el sector de recursos hídricos y saneamiento, donde opera Aquatech, este monitoreo adquiere un carácter de urgencia. Las fisuras en estructuras de retención y conducción de agua no solo comprometen la capacidad de carga, sino que rompen la estanqueidad, permitiendo el ingreso de agentes agresivos (cloruros y sulfatos) que desencadenan la corrosión activa del acero de refuerzo. Actualmente, las inspecciones periciales en Aquatech dependen en gran medida de métodos manuales y visuales (uso de fisurómetros analógicos y registro fotográfico estándar). Esta metodología presenta tres deficiencias fundamentales: es subjetiva (depende del criterio y fatiga del inspector), es ineficiente en tiempo, y carece de trazabilidad geométrica estandarizada.

1.1.1 Identificación y descripción del problema de estudio

En una inspección forense, la rajadura es un indicio: su ancho y su longitud permiten estimar la severidad, su orientación y su patrón sugieren el mecanismo que la origina, y su evolución en el tiempo documenta si el daño avanza. Registrar esa información de forma manual es lento, está expuesto a variaciones entre inspectores y rara vez deja una evidencia que otro perito pueda reproducir. La visión por computador permite automatizar parte de este trabajo y está bien establecida en el monitoreo de salud estructural, donde se aplica a grietas, desprendimientos, delaminación y corrosión [2, 10].

Sin embargo, tres obstáculos impiden trasladar ese avance a una práctica pericial confiable. Primero, los resultados publicados no son comparables: cada estudio usa conjuntos de datos, particiones y métricas distintas (mAP50, mAP50-95, IoU, exactitud), de modo que ninguna clasificación de modelos es defendible sin un protocolo común [5, 11, 12]. Segundo, un modelo entrenado con las imágenes de un dispositivo o de unas condiciones de luz pierde desempeño al cambiar de sensor o de iluminación, y ese deterioro rara vez se mide con YOLO [13, 14]. Tercero, aun cuando se mide el ancho de la grieta, el error suele expresarse en píxeles y sin propagar la incertidumbre a la medida final [7]; para un informe técnico, un ancho sin intervalo de confianza no es evidencia suficiente. A esto se suma que la evidencia revisada por pares sobre YOLO11 aplicada a grietas es reciente y limitada a modificaciones arquitectónicas evaluadas contra sus propias líneas base [6, 12].

1.1.2 Antecedentes de la investigación

A continuación se resumen los antecedentes más cercanos al problema; el estado del arte ampliado figura en el Anexo B.

- Yang et al. [1]: plantearon la detección de grietas a nivel de píxel y su medición con una red completamente convolucional, lo que muestra que la cuantificación es parte del problema desde los primeros trabajos.
- Shokri et al. [9]: publicaron CCSS-DATA, con 670 imágenes RGB de grietas en veredas de concreto y sus etiquetas semánticas, capturadas con cuatro cámaras distintas y bajo condiciones de luz variadas.
- Wu et al. [4]: propusieron LCA-YOLOv8-Seg para segmentación de instancias de grietas en presas y puentes, con una precisión de 0,945 a 129 cuadros por segundo.

- Sohaib et al. [5]: compararon versiones de YOLO para grietas en concreto con transferencia de aprendizaje; YOLOv10 obtuvo el mejor desempeño, con un mAP de 74,52 % y 19,5 ms por imagen.
- Dong et al. [6]: modificaron YOLO11 para grietas de puentes y reportaron incrementos de 3,1 % en mAP50 y 4,8 % en mAP50-95 con 19,05 % menos GFLOPs.
- Deng et al. [7]: integraron detección con YOLOv5, segmentación con Res-UNet y cuantificación; reportaron un mAP de 91 %, una IoU de 87 % y un error cuadrático medio de 2,1 píxeles en el ancho.
- Zhang et al. [12]: combinaron YOLOv11 con SAM en dos etapas y reportaron una IoU de 0,77 y de 0,64 bajo iluminación no uniforme.
- Liu y Yeoh [15]: abordaron el reconocimiento de patrones de agrietamiento para evaluar la condición de estructuras de concreto, el antecedente más cercano al componente forense.

1.1.3 Formulación del problema

Esta tesis se formula como un problema de ingeniería de sistemas de inteligencia artificial con evaluación experimental, delimitado a imágenes RGB de superficies de concreto.

Problema general. ¿En qué medida un sistema de inspección basado en segmentación de instancias con YOLO11, con cuantificación geométrica calibrada y predicción conforme, permite caracterizar rajaduras en superficies de concreto con un error de medición acotado y una cobertura de incertidumbre verificable, incluso cuando cambia el dispositivo de captura?

Formulación de los problemas específicos

1. ¿Cuál es el desempeño de segmentación (IoU de máscara y mAP50-95) de YOLO11-seg frente a YOLOv8-seg en CCSS-DATA bajo un protocolo con particiones fijas y múltiples semillas?
2. ¿Cuánto se degrada ese desempeño al validar dejando fuera una cámara (leave-one-device-out), y qué parte se recupera con aumento fotométrico dirigido?
3. ¿Con qué error se estiman la longitud y el ancho de la rajadura a partir de la máscara, en píxeles y en milímetros, y cómo influye el factor de calibración?
4. ¿Qué cobertura empírica alcanzan los intervalos conformes del ancho y cómo cambia al cambiar de dispositivo?
5. ¿Es la latencia de inferencia compatible con su uso en campo, en CPU y en un dispositivo de borde?

1.2 Justificación y alcances

Esta sección argumenta por qué la investigación es necesaria y define hasta dónde llega.

1.2.1 Justificación

Desde el punto de vista teórico, la tesis aporta un protocolo comparable para evaluar YOLO11-seg frente a YOLOv8-seg en segmentación de grietas, con particiones fijas, semillas múltiples y pruebas de no inferioridad, y cuantifica el costo de cambiar de dispositivo de captura, un aspecto que la literatura revisada reporta de forma parcial [9, 13].

Desde el punto de vista metodológico, incorpora la predicción conforme [8] a la medición del ancho de grietas, de modo que cada valor acompañe un intervalo con cobertura declarada; en la muestra recuperada no se encontró esa combinación para segmentación de grietas.

Desde el punto de vista práctico, el sistema entrega por cada grieta su longitud, su ancho, su orientación, un mapa de explicabilidad [16] y un intervalo de incertidumbre, información que un perito puede auditar y adjuntar a un informe. Al funcionar con imágenes de un teléfono y modelos de tamaño pequeño, reduce el costo de una inspección preliminar y la exposición del inspector a zonas de difícil acceso.

1.2.2 Alcances

El estudio se limita a grietas superficiales en concreto, observadas en imágenes RGB tomadas a distancias de entre 1 y 3 m, como las de CCSS-DATA [9]. No incluye profundidad, grietas internas ni diagnóstico automático de la causa: se entregan descriptores (ancho, longitud, orientación, patrón) para que el perito decida. La conversión a milímetros exige una referencia de escala en la escena (regla, tarjeta o distancia conocida) y se validará con un conjunto de campo de al menos 100 imágenes con lectura de fisurómetro. El sistema es una ayuda para la inspección y construcción del informe técnico del ingeniero profesional.

CAPÍTULO 2: OBJETIVOS

2.1 Objetivo general

Desarrollar y validar un sistema de inspección forense de rajaduras en superficies de concreto que segmente instancias con YOLO11, cuantifique su longitud y ancho con calibración física y acompañe cada medida con un intervalo de incertidumbre conforme, evaluando su desempeño frente a una línea base YOLOv8-seg y su robustez al cambiar de dispositivo de captura.

2.2 Objetivos específicos

1. Analizar el estado del arte y los antecedentes sobre detección, segmentación y cuantificación de grietas con YOLO, y consolidar un protocolo experimental comparable.
2. Preparar los datos: auditar CCSS-DATA, definir particiones aleatoria y por dispositivo, y levantar un conjunto de campo con referencia física de al menos 100 imágenes.
3. Entrenar y comparar YOLO11-seg y YOLOv8-seg (variantes n y s) con cinco semillas, reportando IoU, Dice, mAP50-95, parámetros y latencia.
4. Diseñar e implementar el módulo de cuantificación (esqueletización y transformada de distancia) con factor de calibración en mm/px, y validar su error de longitud y de ancho.
5. Incorporar predicción conforme y mapas de explicabilidad, y evaluar la cobertura empírica de los intervalos dentro y fuera del dominio de entrenamiento.
6. Evaluar el sistema integrado en condiciones de campo y generar el informe técnico automático por imagen.
7. Proponer recomendaciones y lineamientos de uso pericial a partir de los hallazgos y de las limitaciones identificadas.

CAPÍTULO 3: MARCO TEÓRICO

3.1 Bases teóricas

Esta sección sustenta los pilares científicos del sistema propuesto: la segmentación de instancias con YOLO, la cuantificación geométrica a partir de la máscara, la incertidumbre calibrada y la evaluación entre dominios.

3.1.1 Rajaduras y patologías del concreto

Una rajadura es una discontinuidad visible en la superficie de un elemento de concreto o albañilería. Su ancho, su longitud, su orientación y su distribución sobre el elemento son las variables que un inspector registra para clasificar la severidad y orientar el diagnóstico, y los trabajos de visión por computador las han formalizado como problemas de detección, segmentación y medición [1,2]. La clasificación por ancho depende de la guía técnica que se adopte, y la tesis fijará una única taxonomía, con su referencia normativa, junto con el asesor.

3.1.2 YOLO y segmentación de instancias

YOLO resuelve la detección en una sola pasada de la red, con un compromiso entre velocidad y precisión que la ha hecho dominante en aplicaciones en tiempo real [3, 17]. En su variante de segmentación, la red predice por cada instancia una caja, una clase y coeficientes que combinan un conjunto de prototipos de máscara, un esquema que proviene de la segmentación de instancias en tiempo real tipo YOLACT [18]; frente a los detectores de dos etapas como Mask R-CNN [19] reduce la latencia. La implementación de YOLO11 que se usará es el software mantenido por Ultralytics[1], por lo que la tesis documentará versión, hiperparámetros y semillas. La eficacia del esquema en grietas ya fue mostrada para YOLOv8-seg [4], mientras que la evidencia sobre YOLO11 se limita a variantes modificadas [6, 12].

3.1.3 Cuantificación geométrica de la máscara

Dada una máscara binaria M de una grieta, se calcula su esqueleto morfológico S y la transformada de distancia euclídea $D(p)$, que asigna a cada píxel de la máscara su distancia al fondo más cercano. El ancho local en un píxel $p \in S$ es $w(p) = 2\,D(p)$ y la longitud se estima como la longitud geodésica del esqueleto. Con un factor de escala s (mm/px), obtenido de una referencia en la escena o de la distancia de muestreo del terreno, las medidas físicas son $w_{\text{mm}} = s\,w$ y $L_{\text{mm}} = s\,L$. Este tipo de cuantificación a partir de la segmentación está presente en los trabajos revisados [7,20,21], pero su error suele expresarse en píxeles y sin incertidumbre.

3.1.4 Incertidumbre y predicción conforme

La incertidumbre de un modelo profundo se descompone en una parte del modelo (reducible) y una de los datos (irreducible) [22], y existen revisiones de las técnicas para estimarla [23]. La predicción conforme [8] produce conjuntos o intervalos con cobertura garantizada sin supuestos distribucionales, usando cualquier modelo preentrenado. En su versión de partición se calculan los residuos absolutos $s_i = |w_i - \hat{w}_i|$ en un conjunto de calibración de tamaño n, se toma el cuantil $\hat{q}$ de orden $\lceil (n+1)(1 -$

[1] Ultralytics, YOLO11 , `https://github.com/ultralytics/ultralytics`.

$\alpha)\rceil/n$ y se reporta el intervalo $[\hat{w}-\hat{q},\ \hat{w}+\hat{q}]$, que cubre el valor verdadero con probabilidad al menos $1-\alpha$ si calibración y prueba son intercambiables. Bajo cambio de dispositivo esa garantía puede perderse, y la tesis medirá cuánto.

3.1.5 Generalización entre dominios y explicabilidad

Un modelo entrenado con las imágenes de una cámara puede degradarse al cambiar de sensor, resolución o iluminación; la generalización de dominio estudia cómo reducir ese costo sin acceso al dominio objetivo [24], y la adaptación no supervisada lo hace con datos no etiquetados del nuevo dominio [13]. Como protocolo de evaluación se usará la validación dejando un dispositivo fuera (leave-one-device-out). Para auditar qué región de la imagen sustenta una detección se emplearán mapas de activación tipo Grad-CAM [16].

3.1.6 Métricas de evaluación

Para una máscara predicha P y una máscara de referencia G, la IoU es $|P\cap G|/|P\cup G|$ y el coeficiente de Dice es $2|P\cap G|/(|P|+|G|)$. El mAP50-95 promedia la precisión media sobre umbrales de IoU de 0,50 a 0,95. El error absoluto medio del ancho es MAE $=\frac{1}{N}\sum_i|\hat{w}_i-w_i|$, y la cobertura empírica de los intervalos conformes es la fracción de casos de prueba en que el valor de referencia cae dentro del intervalo.

3.2 Definición de términos

A continuación se definen los términos fundamentales que se usan en el documento.

Rajadura (grieta, fisura). Discontinuidad visible en la superficie del concreto; en este documento se usan como sinónimos operativos del término crack de la literatura, a la espera de la taxonomía por ancho que se adopte.

Inspección forense. Examen técnico orientado a documentar y explicar el daño de una estructura con evidencia trazable y reproducible.

Segmentación de instancias. Tarea que asigna a cada objeto una máscara a nivel de píxel y la distingue de otras instancias de la misma clase.

IoU y Dice. Medidas de solapamiento entre la máscara predicha y la de referencia.

mAP50-95. Precisión media promediada sobre umbrales de IoU de 0,50 a 0,95.

Esqueleto y transformada de distancia. Representación de la línea central de una máscara y distancia de cada píxel al fondo, usadas para medir longitud y ancho.

Factor de escala. Relación mm/px que convierte medidas de imagen a medidas físicas.

Predicción conforme. Método que produce intervalos con cobertura garantizada sin supuestos sobre la distribución.

Cobertura empírica. Fracción de casos de prueba en que el valor de referencia cae dentro del intervalo predicho.

Cambio de dominio. Diferencia entre las condiciones de entrenamiento y de uso, como el sensor, la resolución o la iluminación.

Leave-one-device-out. Validación que entrena con todos los dispositivos excepto uno y prueba en el excluido.

3.3 Hipótesis y variables

3.3.1 Hipótesis general

Un sistema basado en YOLO11-seg con cuantificación geométrica calibrada y predicción conforme logra, sobre CCSS-DATA y bajo validación entre dispositivos, una IoU de máscara no inferior a la de YOLOv8-seg (margen de no inferioridad de 0,02), un error absoluto medio de ancho menor o igual a 1,5 píxeles respecto de la referencia y una cobertura empírica del 90 % $\pm$ 3 puntos porcentuales.

Hipótesis específicas

H1. YOLO11n-seg no es inferior a YOLOv8n-seg en IoU de máscara sobre la partición fija de CCSS-DATA, con un margen de 0,02 y un IC de 95 % unilateral.

H2. La IoU de máscara cae al menos 0,05 al pasar de la partición aleatoria a la validación dejando un dispositivo fuera, y el aumento fotométrico dirigido recupera al menos el 30 % de esa caída.

H3. El error absoluto medio del ancho estimado desde la máscara predicha es menor o igual a 1,5 píxeles respecto del ancho derivado de la máscara de referencia, y el factor de calibración introduce un error relativo menor o igual al 5 % en milímetros sobre el conjunto de campo.

H4. Los intervalos conformes del ancho alcanzan una cobertura empírica de 90 % $\pm$ 3 puntos porcentuales con partición aleatoria y de al menos 85 % con validación dejando un dispositivo fuera.

3.3.2 Variables de la investigación

Las variables independientes son los factores que se manipulan; las dependientes, los resultados que se miden; y las intervinientes, las condiciones externas que influyen en el resultado y deben controlarse o reportarse. Por ejemplo, la iluminación es interviniente: aunque el modelo sea adecuado, una iluminación deficiente reduce la IoU sin que sea un error del algoritmo, como sugiere la diferencia de IoU que reporta Zhang et al. [12] entre iluminación general y no uniforme. Las variables se resumen en la Tabla 3.1.

Tabla 3.1: Variables de la investigación

Tipo de variable	Variable	Indicador / unidad
Independiente	Arquitectura del modelo	YOLOv8-seg frente a YOLO11-seg; tamaño n o s
Independiente	Estrategia de entrenamiento	Aumento estándar frente a aumento fotométrico dirigido
Independiente	Dispositivo de captura	Canon EOS M5, Xiaomi Mi A1, ZED, Samsung Galaxy S7
Dependiente	Calidad de segmentación	IoU y Dice de máscara; mAP50-95 (adimensional)
Dependiente	Error de medición	MAE del ancho y de la longitud (px y mm)
Dependiente	Calidad de la incertidumbre	Cobertura empírica y ancho medio del intervalo
Dependiente	Eficiencia	Parámetros (M) y latencia (ms por imagen)
Interviniente	Iluminación y sombras	Condición de captura (general frente a no uniforme)
Interviniente	Distancia y resolución	Distancia de captura (m) y tamaño de imagen (px)
Interviniente	Textura de la superficie	Presencia de juntas, manchas y vegetación

CAPÍTULO 4: DISEÑO METODOLÓGICO

El presente capítulo describe el diseño metodológico. La investigación se enmarca en un enfoque cuantitativo de tipo experimental computacional: se evalúa el desempeño de modelos de aprendizaje profundo y de un módulo de medición sobre conjuntos de datos definidos, comparando resultados mediante métricas estandarizadas y pruebas estadísticas.

4.1 Tipo de investigación

La investigación es de tipo aplicado y tecnológico. Es aplicada porque busca resolver el problema de la caracterización objetiva de rajaduras en concreto mediante conocimientos de inteligencia artificial, y es tecnológica porque se centra en el desarrollo y la validación de un sistema (modelo, módulo de medición e informe técnico) cuyo desempeño se mide de forma cuantitativa.

4.2 Nivel de investigación

El nivel es explicativo-experimental. No solo se describirá cuánto mejora o empeora cada configuración, sino que se explicará qué factores (versión del modelo, estrategia de entrenamiento y dispositivo de captura) producen los cambios, mediante comparaciones controladas con las mismas particiones y semillas.

4.3 Métodos de trabajo

Se utilizará el método deductivo-experimental, en tres fases:

- Fase analítica: revisión sistemática del estado del arte y fijación del protocolo (datos, particiones, métricas y pruebas).
- Fase sintética: construcción del sistema, que integra segmentación con YOLO11, cuantificación geométrica, predicción conforme y explicabilidad.
- Fase experimental: entrenamiento y evaluación con múltiples semillas, validación entre dispositivos y validación de campo con referencia física.

4.4 Población y muestra

Se define a continuación el universo de estudio y los conjuntos de datos con los que se trabajará.

4.4.1 Población

La población es de 56000 imágenes .JPG de superficies de concreto con rajaduras visibles y sin rajaduras capturadas con cámaras de uso corriente en condiciones de inspección, a distancias de 1 a 3 m. El conjunto de datos incluye grietas con una anchura mínima de 0,06 mm y una máxima de 25 mm.

4.4.2 Muestra

La muestra principal es [9]: 670 imágenes RGB con etiquetas de segmentación semántica de grietas de concreto, de las cuales 308 provienen de una cámara Canon EOS M5, 124 de un Xiaomi Mi A1, 155 de una cámara estéreo ZED y 83 de un Samsung Galaxy S7. El dataset describe además una combinación de

1 128 imágenes con una partición de 721 para entrenamiento, 181 para validación y 226 para prueba. Se definirán dos esquemas de partición con semilla fija: una partición aleatoria estratificada por dispositivo (70 / 15 / 15) y cuatro particiones leave-one-device-out. A ello se suma un conjunto de campo de al menos 100 imágenes de edificaciones, con regla de escala en la escena y lectura de fisurómetro como referencia física del ancho.

4.5 Tipo de diseño

El diseño es experimental computacional de tipo factorial, con tres factores: versión del modelo (YOLOv8-seg frente a YOLO11-seg, tamaños n y s), estrategia de entrenamiento (aumento estándar frente a aumento fotométrico dirigido) y esquema de partición (aleatoria frente a leave-one-device-out). Cada configuración se entrena con cinco semillas. Por la naturaleza computacional del estudio, la asignación es controlada: todas las configuraciones comparten particiones, número de épocas y tamaño de imagen.

4.6 Técnicas e instrumentos de recolección de datos

Se usarán datos secundarios públicos (CCSS-DATA) y datos primarios de campo. Los instrumentos son:

- Cámara de teléfono móvil con distancia de captura registrada y regla de escala o tarjeta de calibración en la escena.
- Informe de imágenes de rajadura con lectura de Fisurómetro para la toma de referencia del ancho en puntos marcados.
- Herramienta de anotación de máscaras (CVAT o Label Studio) con guía de etiquetado y doble revisión sobre una submuestra.

4.7 Técnicas e instrumentos de análisis y procesamiento de datos

Se usará estadística descriptiva e inferencial, con los siguientes instrumentos:

- Python con PyTorch, Ultralytics, OpenCV y scikit-image para entrenamiento, inferencia, esqueletización y transformada de distancia.
- Intervalos de confianza del 95 % por bootstrap pareado sobre las imágenes de prueba (10 000 remuestreos), combinado con las cinco semillas.
- Prueba de no inferioridad con margen de 0,02 en IoU (IC de 95 % unilateral) para comparar YOLO11-seg con YOLOv8-seg, y comparaciones pareadas con corrección de Holm cuando haya varias.
- Cobertura empírica y ancho medio de los intervalos conformes, con tamaños de calibración y de prueba reportados.

4.8 Etapas de intervención del estudio

1. Etapa de datos: auditoría del dataset, definición de particiones, levantamiento y anotación del conjunto de campo.

2. Etapa de modelado: entrenamiento de YOLOv8-seg y YOLO11-seg con cinco semillas y comparación bajo el protocolo fijo.
3. Etapa de medición: implementación y validación del módulo de cuantificación con calibración.
4. Etapa de incertidumbre y explicabilidad: calibración conforme y mapas Grad-CAM, con evaluación de cobertura.
5. Etapa de evaluación: validación entre informe técnico profesional y medición de latencia.

4.9 Justificación de la metodología

Se eligió un diseño experimental con particiones fijas, semillas múltiples y pruebas estadísticas porque la literatura revisada reporta resultados sobre conjuntos y métricas distintas, lo que impide comparar modelos [5,6]. La validación entre dispositivos se justifica porque el cambio de sensor y de iluminación es la principal amenaza a la validez externa de estos modelos [12,13], y la predicción conforme porque ofrece garantías de cobertura sin depender de la arquitectura [8]. El conjunto de campo con referencia física permite verificar la conversión a milímetros, algo que no puede comprobarse con las máscaras del dataset.

CAPÍTULO 5: ADMINISTRACIÓN DEL PLAN DE TESIS

5.1 Cronograma

Se propone un plan de trabajo de 10 meses, dividido en fases que van desde la revisión teórica hasta la validación de campo y la redacción. En la Tabla 5.1 los períodos son meses consecutivos contados desde el inicio del proyecto (abril del 2026).

Tabla 5.1: Cronograma de actividades

		Mes									
Fase	**Actividad**	**1**	**2**	**3**	**4**	**5**	**6**	**7**	**8**	**9**	**10**
Planificación	Revisión bibliográfica y protocolo experimental	X	X								
Datos	Auditoría del dataset y máscaras, particiones y levantamiento de campo		X	X	X	X					
Modelado	Entrenamiento y comparación YOLOv8-seg y YOLO11-seg					X	X				
Medición	Módulo de cuantificación y calibración						X	X			
Incertidumbre	Predicción conforme y explicabilidad							X	X		
Validación	Validación entre imagenes oficiales campo								X	X	
Análisis	Análisis estadístico y artículo científico								X	X	
Finalización	Redacción de tesis y preparación de la sustentación									X	X

5.2 Presupuesto

El presupuesto detalla los recursos necesarios, divididos en bienes (equipos y materiales) y servicios (cómputo, anotación y publicación). Los montos son referenciales y se actualizarán con cotizaciones. La estación de trabajo (laptop del investigador) y el teléfono de captura son de uso propio y no se presupuestan. La inversión total estimada es de USD 1,460.00.

5.2.1 Bienes

Tabla 5.2: Presupuesto de recursos materiales

Ítem	**Descripción**	**Cant.**	**Costo (USD)**
Fisurómetro	Comparador de fisuras para lectura de referencia del ancho	1	$35.00
Escala de calibración	Reglas y tarjetas de escala impresas	1	$25.00
Medidor láser	Medidor de distancia para registrar la distancia de captura	1	$80.00
Trípode	Trípode con soporte para teléfono	1	$30.00
Almacenamiento	Disco SSD externo de 2 TB para imágenes y modelos	1	$120.00
		TOTAL	**$290.00**

Tabla 5.3: Presupuesto de recursos intangibles

Ítem	Descripción	Costo (USD)
Cómputo en la nube	Horas de GPU para entrenamiento (aprox. 150 h)	$300.00
Anotación	Plataforma de anotación y revisión (plan académico)	$120.00
Publicación	Pago por procesamiento de artículo (APC) en revista indexada	$500.00
Trabajo de campo	Transporte y logística para el levantamiento de imágenes	$150.00
Impresión	Impresión y empastado del documento final	$100.00
	TOTAL	**$1,170.00**

5.2.2 Servicios

5.3 Financiamiento

El proyecto se podrá financiar con recursos propios y en colaboración de la empresa Aquatech para las pruebas de campo.

- Recursos propios: bienes, trabajo de campo, impresión y gastos operativos menores, a cargo del investigador.
- Fondos externos: fondos Aquatech

5.3.1 Consideraciones finales

- Gestión de riesgos: la principal amenaza es la validez externa; se mitiga con el conjunto de campo. Otros riesgos son la falta de GPU local, que se cubre con cómputo en la nube, y la variabilidad de la anotación, que se controla con una guía de etiquetado y doble revisión.
- Aspectos éticos y legales: las imágenes de edificaciones requieren autorización del propietario o administrador y se anonimizarán si contienen personas o placas. El uso de la biblioteca Ultralytics, que se distribuye con licencia AGPL-3.0, se revisará antes de publicar el código.
- Alcance profesional: los resultados son una ayuda para la inspección y no sustituyen el criterio de un ingeniero colegiado.

REFERENCIAS BIBLIOGRÁFICAS

[1] X. Yang, H. Li, Y. Yu, X. Luo, T. Huang, and X. Yang, "Automatic Pixel-Level Crack Detection and Measurement Using Fully Convolutional Network," *Computer-Aided Civil and Infrastructure Engineering*, vol. 33, no. 12, pp. 1090–1109, 2018, doi: 10.1111/mice.12412.

[2] C.-Z. Dong and F. N. Catbas, "A review of computer vision–based structural health monitoring at local and global levels," *Structural Health Monitoring*, vol. 20, no. 2, pp. 692–743, 2020, doi: 10.1177/1475921720935585.

[3] J. Terven, D.-M. Córdova-Esparza, and J.-A. Romero-González, "A Comprehensive Review of YOLO Architectures in Computer Vision: From YOLOv1 to YOLOv8 and YOLO-NAS," *Machine Learning and Knowledge Extraction*, vol. 5, no. 4, pp. 1680–1716, 2023, doi: 10.3390/make5040083.

[4] Y. Wu, Q. Han, Q. Jin, J. Li, and Y. Zhang, "LCA-YOLOv8-Seg: An Improved Lightweight YOLOv8-Seg for Real-Time Pixel-Level Crack Detection of Dams and Bridges," *Applied Sciences*, vol. 13, no. 19, Art. 10583, 2023, doi: 10.3390/app131910583.

[5] M. Sohaib, M. Arif, and J.-M. Kim, "Evaluating YOLO Models for Efficient Crack Detection in Concrete Structures Using Transfer Learning," *Buildings*, vol. 14, no. 12, Art. 3928, 2024, doi: 10.3390/buildings14123928.

[6] X. Dong, J. Yuan, and J. Dai, "Study on Lightweight Bridge Crack Detection Algorithm Based on YOLO11," *Sensors*, vol. 25, no. 11, Art. 3276, 2025, doi: 10.3390/s25113276.

[7] L. Deng, A. Zhang, J. Guo, and Y. Liu, "An Integrated Method for Road Crack Segmentation and Surface Feature Quantification under Complex Backgrounds," *Remote Sensing*, vol. 15, no. 6, Art. 1530, 2023, doi: 10.3390/rs15061530.

[8] A. N. Angelopoulos and S. Bates, "Conformal Prediction: A Gentle Introduction," *Foundations and Trends® in Machine Learning*, vol. 16, no. 4, pp. 494–591, 2023, doi: 10.1561/2200000101.

[9] P. Shokri, M. Shahbazi, and J. Nielsen, "Semantic Segmentation and 3D Reconstruction of Concrete Cracks," *Remote Sensing*, vol. 14, no. 22, Art. 5793, 2022, doi: 10.3390/rs14225793.

[10] B. F. Spencer, V. Hoskere, and Y. Narazaki, "Advances in Computer Vision-Based Civil Infrastructure Inspection and Monitoring," *Engineering*, vol. 5, no. 2, pp. 199–222, 2019, doi: 10.1016/j.eng.2018.11.030.

[11] X. Dong, Y. Liu, and J. Dai, "Concrete Surface Crack Detection Algorithm Based on Improved YOLOv8," *Sensors*, vol. 24, no. 16, Art. 5252, 2024, doi: 10.3390/s24165252.

[12] R. Zhang, C. Guan, Y. Fang, Y. Duan, and X. Sui, "A Two-Stage Concrete Crack Segmentation Method Based on the Improved YOLOv11 and Segment Anything Model," *Buildings*, vol. 16, no. 4, Art. 794, 2026, doi: 10.3390/buildings16040794.

[13] X. Weng, Y. Huang, Y. Li, H. Yang, and S. Yu, "Unsupervised domain adaptation for crack detection," *Automation in Construction*, vol. 153, Art. 104939, 2023, doi: 10.1016/j.autcon.2023.104939.

[14] J. Shan, W. Jiang, and X. Feng, "Bridging cross-domain and cross-resolution gaps for UAV-based pavement crack segmentation," *Automation in Construction*, vol. 174, Art. 106141, 2025, doi: 10.1016/j.autcon.2025.106141.

[15] Y. Liu and J. K. Yeoh, "Automated crack pattern recognition from images for condition assessment of concrete structures," *Automation in Construction*, vol. 128, Art. 103765, 2021, doi: 10.1016/j.autcon.2021.103765.

[16] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, "Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization," *International Journal of Computer Vision*, vol. 128, no. 2, pp. 336–359, 2019, doi: 10.1007/s11263-019-01228-7.

[17] M. Hussain, "YOLO-v1 to YOLO-v8, the Rise of YOLO and Its Complementary Nature toward Digital Manufacturing and Industrial Defect Detection," *Machines*, vol. 11, no. 7, Art. 677, 2023, doi: 10.3390/machines11070677.

[18] D. Bolya, C. Zhou, F. Xiao, and Y. J. Lee, "YOLACT++ Better Real-Time Instance Segmentation," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 44, no. 2, pp. 1108–1121, 2022, doi: 10.1109/tpami.2020.3014297.

[19] K. He, G. Gkioxari, P. Dollar, and R. Girshick, "Mask R-CNN," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 42, no. 2, pp. 386–397, 2020, doi: 10.1109/tpami.2018.2844175.

[20] L. Minh Dang *et al.*, "Deep learning-based masonry crack segmentation and real-life crack length measurement," *Construction and Building Materials*, vol. 359, Art. 129438, 2022, doi: 10.1016/j.conbuildmat.2022.129438.

[21] Z. Li *et al.*, "Automated quantification of crack length and width in asphalt pavements," *Computer-Aided Civil and Infrastructure Engineering*, vol. 39, no. 21, pp. 3317–3336, 2024, doi: 10.1111/mice.13344.

[22] J. Gawlikowski *et al.*, "A survey of uncertainty in deep neural networks," *Artificial Intelligence Review*, vol. 56, no. S1, pp. 1513–1589, 2023, doi: 10.1007/s10462-023-10562-9.

[23] M. Abdar *et al.*, "A review of uncertainty quantification in deep learning: Techniques, applications and challenges," *Information Fusion*, vol. 76, pp. 243–297, 2021, doi: 10.1016/j.inffus.2021.05.008.

[24] K. Zhou, Z. Liu, Y. Qiao, T. Xiang, and C. C. Loy, "Domain Generalization: A Survey," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, pp. 1–20, 2022, doi: 10.1109/tpami.2022.3195549.

[25] H. Zhuang, Y. Cheng, M. Zhou, and Z. Yang, "Deep learning for surface crack detection in civil engineering: A comprehensive review," *Measurement*, vol. 248, Art. 116908, 2025, doi: 10.1016/j.measurement.2025.116908.

[26] Y. Cha, W. Choi, and O. Büyüköztürk, "Deep Learning-Based Crack Damage Detection Using Convolutional Neural Networks," *Computer-Aided Civil and Infrastructure Engineering*, vol. 32, no. 5, pp. 361–378, 2017, doi: 10.1111/mice.12263.

[27] C. V. Dung and L. D. Anh, "Autonomous concrete crack detection using deep fully convolutional neural network," *Automation in Construction*, vol. 99, pp. 52–58, 2019, doi: 10.1016/j.autcon.2018.11.028.

[28] Y. Shi, L. Cui, Z. Qi, F. Meng, and Z. Chen, "Automatic Road Crack Detection Using Random Structured Forests," *IEEE Transactions on Intelligent Transportation Systems*, vol. 17, no. 12, pp. 3434–3445, 2016, doi: 10.1109/tits.2016.2552248.

[29] Q. Zou, Z. Zhang, Q. Li, X. Qi, Q. Wang, and S. Wang, "DeepCrack: Learning Hierarchical Convolutional Features for Crack Detection," *IEEE Transactions on Image Processing*, vol. 28, no. 3, pp. 1498–1512, 2019, doi: 10.1109/tip.2018.2878966.

[30] Y. Liu, J. Yao, X. Lu, R. Xie, and L. Li, "DeepCrack: A deep hierarchical feature learning architecture for crack segmentation," *Neurocomputing*, vol. 338, pp. 139–153, 2019, doi: 10.1016/j.neucom.2019.01.036.

[31] F. Yang, L. Zhang, S. Yu, D. Prokhorov, X. Mei, and H. Ling, "Feature Pyramid and Hierarchical Boosting Network for Pavement Crack Detection," *IEEE Transactions on Intelligent Transportation Systems*, vol. 21, no. 4, pp. 1525–1535, 2020, doi: 10.1109/tits.2019.2910595.

[32] D. Kang, S. S. Benipal, D. L. Gopal, and Y.-J. Cha, "Hybrid pixel-level concrete crack segmentation and quantification across complex backgrounds using deep learning," *Automation in Construction*, vol. 118, Art. 103291, 2020, doi: 10.1016/j.autcon.2020.103291.

[33] W. Wang and C. Su, "Automatic concrete crack segmentation model based on transformer," *Automation in Construction*, vol. 139, Art. 104275, 2022, doi: 10.1016/j.autcon.2022.104275.

[34] J. Wang *et al.*, "Dual-path network combining CNN and transformer for pavement crack segmentation," *Automation in Construction*, vol. 158, Art. 105217, 2024, doi: 10.1016/j.autcon.2023.105217.

[35] S. Dorafshan, R. J. Thomas, and M. Maguire, "SDNET2018: An annotated image dataset for non-contact concrete crack detection using deep convolutional neural networks," *Data in Brief*, vol. 21, pp. 1664–1668, 2018, doi: 10.1016/j.dib.2018.11.015.

[36] D. Arya, H. Maeda, S. K. Ghosh, D. Toshniwal, and Y. Sekimoto, "RDD2022 : A multi-national image dataset for automatic road damage detection," *Geoscience Data Journal*, Art. gdj3.260, 2024, doi: 10.1002/gdj3.260.

[37] L. T. Ramos and A. D. Sappa, "A Decade of You Only Look Once (YOLO) for Object Detection: A Review," *IEEE Access*, vol. 13, pp. 192747–192794, 2025, doi: 10.1109/access.2025.3630988.

[38] A. Vijayakumar and S. Vairavasundaram, "YOLO-based Object Detection Models: A Review and its Applications," *Multimedia Tools and Applications*, vol. 83, no. 35, pp. 83535–83574, 2024, doi: 10.1007/s11042-024-18872-y.

[39] S. Ren, K. He, R. Girshick, and J. Sun, "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 39, no. 6, pp. 1137–1149, 2017, doi: 10.1109/tpami.2016.2577031.

[40] K. Yang, Y. Bao, J. Li, T. Fan, and C. Tang, "Deep learning-based YOLO for crack segmentation and measurement in metro tunnels," *Automation in Construction*, vol. 168, Art. 105818, 2024, doi: 10.1016/j.autcon.2024.105818.

[41] W. Ren and Z. Zhong, "Building construction crack detection with BCCD YOLO enhanced feature fusion and attention mechanisms," *Scientific Reports*, vol. 15, no. 1, Art. 23167, 2025, doi: 10.1038/s41598-025-05665-y.

[42] G. Su, Y. Qin, H. Xu, and J. Liang, "Automatic real-time crack detection using lightweight deep learning models," *Engineering Applications of Artificial Intelligence*, vol. 138, Art. 109340, 2024, doi: 10.1016/j.engappai.2024.109340.

[43] G. Zhu, S.-L. Shen, J. Yao, M. Wang, J. Zhuang, and Z. Fan, "Automatic lightweight networks for real-time road crack detection with DPSO," *Advanced Engineering Informatics*, vol. 68, Art. 103610, 2025, doi: 10.1016/j.aei.2025.103610.

[44] J. Zeng and H. Zhong, "YOLOv8-PD: an improved road damage detection algorithm based on YOLOv8n model," *Scientific Reports*, vol. 14, no. 1, Art. 12052, 2024, doi: 10.1038/s41598-024-62933-z.

[45] S. Zhou *et al.*, "Enhancing autonomous pavement crack detection: Optimizing YOLOv5s algorithm with advanced deep learning techniques," *Measurement*, vol. 240, Art. 115603, 2025, doi: 10.1016/j.measurement.2024.115603.

[46] F. Ni, J. Zhang, and Z. Chen, "Zernike-moment measurement of thin-crack width in images enabled by dual-scale deep learning," *Computer-Aided Civil and Infrastructure Engineering*, vol. 34, no. 5, pp. 367–384, 2019, doi: 10.1111/mice.12421.

[47] K. Yang, Y. Ding, P. Sun, H. Jiang, and Z. Wang, "Computer vision-based crack width identification using F-CNN model and pixel nonlinear calibration," *Structure and Infrastructure Engineering*, vol. 19, no. 7, pp. 978–989, 2021, doi: 10.1080/15732479.2021.1994617.

[48] X. Peng, X. Zhong, C. Zhao, A. Chen, and T. Zhang, "A UAV-based machine vision method for bridge crack recognition and width quantification through hybrid feature learning," *Construction and Building Materials*, vol. 299, Art. 123896, 2021, doi: 10.1016/j.conbuildmat.2021.123896.

[49] J. C. Ong, M.-Z. P. Ismadi, and X. Wang, "A hybrid method for pavement crack width measurement," *Measurement*, vol. 197, Art. 111260, 2022, doi: 10.1016/j.measurement.2022.111260.

[50] S. Xu, H. Tang, X. Wang, and D. Wang, "Assessment of geometric parameters of segmented crack on concrete building facade using deep learning," *Structures*, vol. 57, Art. 105188, 2023, doi: 10.1016/j.istruc.2023.105188.

[51] Y.-C. Chen, R.-T. Wu, and A. Puranam, "Multi-task deep learning for crack segmentation and quantification in RC structures," *Automation in Construction*, vol. 166, Art. 105599, 2024, doi: 10.1016/j.autcon.2024.105599.

[52] J. Xu, C. Yuan, J. Gu, J. Liu, J. An, and Q. Kong, "Innovative synthetic data augmentation for dam crack detection, segmentation, and quantification," *Structural Health Monitoring*, vol. 22, no. 4, pp. 2402–2426, 2022, doi: 10.1177/14759217221122318.

[53] K. Chen, G. Reichard, X. Xu, and A. Akanmu, "Automated crack segmentation in close-range building façade inspection images using deep learning techniques," *Journal of Building Engineering*, vol. 43, Art. 102913, 2021, doi: 10.1016/j.jobe.2021.102913.

[54] S. Katsigiannis, S. Seyedzadeh, A. Agapiou, and N. Ramzan, "Deep learning for crack detection on masonry façades using limited data and transfer learning," *Journal of Building Engineering*, vol. 76, Art. 107105, 2023, doi: 10.1016/j.jobe.2023.107105.

[55] K. Hacıefendioğlu, A. C. Altunışık, and T. Abdioğlu, "Deep Learning-Based Automated Detection of Cracks in Historical Masonry Structures," *Buildings*, vol. 13, no. 12, Art. 3113, 2023, doi: 10.3390/buildings13123113.

[56] A. Y. Yiğit and M. Uysal, "Automatic crack detection and structural inspection of cultural heritage buildings using UAV photogrammetry and digital twin technology," *Journal of Building Engineering*, vol. 94, Art. 109952, 2024, doi: 10.1016/j.jobe.2024.109952.

[57] H. Perez, J. H. M. Tah, and A. Mosavi, "Deep Learning for Detecting Building Defects Using Convolutional Neural Networks," *Sensors*, vol. 19, no. 16, Art. 3556, 2019, doi: 10.3390/s19163556.

[58] M. Zheng, Z. Lei, and K. Zhang, "Intelligent detection of building cracks based on deep learning," *Image and Vision Computing*, vol. 103, Art. 103987, 2020, doi: 10.1016/j.imavis.2020.103987.

[59] Y. Z. Ayele, M. Aliyari, D. Griffiths, and E. L. Droguett, "Automatic Crack Segmentation for UAV-Assisted Bridge Inspection," *Energies*, vol. 13, no. 23, Art. 6250, 2020, doi: 10.3390/en13236250.

[60] W. Wang and C. Su, "Semi-supervised semantic segmentation network for surface crack detection," *Automation in Construction*, vol. 128, Art. 103786, 2021, doi: 10.1016/j.autcon.2021.103786.

[61] Q. D. Nguyen and H.-T. Thai, "Crack segmentation of imbalanced data: The role of loss functions," *Engineering Structures*, vol. 297, Art. 116988, 2023, doi: 10.1016/j.engstruct.2023.116988.

[62] K. Ge, C. Wang, Y. Guo, Y. Tang, Z. Hu, and H. Chen, "Fine-tuning vision foundation model for crack segmentation in civil infrastructures," *Construction and Building Materials*, vol. 431, Art. 136573, 2024, doi: 10.1016/j.conbuildmat.2024.136573.

[63] Y. Guo, Y. Xu, H. Cui, M. Dang, and S. Li, "Segment anything model-based crack segmentation using low-rank adaption fine-tuning," *Structural Health Monitoring*, vol. 24, no. 4, pp. 2579–2591, 2024, doi: 10.1177/14759217241261089.

[64] S. O. Sajedi and X. Liang, "Uncertainty-assisted deep vision structural health monitoring," *Computer-Aided Civil and Infrastructure Engineering*, vol. 36, no. 2, pp. 126–142, 2021, doi: 10.1111/mice.12580.

[65] C. Zhang, M. Bahrami, D. K. Mishra, M. M. Yuen, Y. Yu, and J. Zhang, "SelectSeg: Uncertainty-based selective training and prediction for accurate crack segmentation under limited data and noisy annotations," *Reliability Engineering & System Safety*, vol. 259, Art. 110909, 2025, doi: 10.1016/j.ress.2025.110909.

ANEXOS

Anexo A. Matriz de consistencia

La matriz de consistencia verifica la coherencia lógica entre el problema, los objetivos, las hipótesis y la metodología (Tabla A.1).

Tabla A.1: Matriz de consistencia

Problema	**Objetivos**	**Hipótesis y variables**	**Metodología**
¿En qué medida un sistema basado en YOLO11-seg, con cuantificación geométrica calibrada y predicción conforme, caracteriza rajaduras en concreto con error acotado y cobertura verificable al cambiar de dispositivo?	Desarrollar y validar un sistema de inspección forense de rajaduras con YOLO11-seg, cuantificación calibrada e incertidumbre conforme, frente a una línea base YOLOv8-seg.	Un sistema YOLO11-seg con cuantificación calibrada y predicción conforme logra IoU no inferior a YOLOv8-seg (margen 0,02), MAE de ancho $\leq$ 1,5 px y cobertura de 90 % $\pm$ 3 pp.	Tipo: aplicada y tecnológica. Nivel: explicativo-experimental.
1. ¿Cuál es el desempeño de YOLO11-seg frente a YOLOv8-seg en CCSS-DATA con protocolo fijo? 2. ¿Cuánto se degrada al dejar un dispositivo fuera? 3. ¿Con qué error se estiman longitud y ancho? 4. ¿Qué cobertura alcanzan los intervalos conformes? 5. ¿Es compatible la latencia con el uso en campo?	1. Consolidar el estado del arte y el protocolo. 2. Preparar datos (CCSS-DATA y campo). 3. Entrenar y comparar modelos con cinco semillas. 4. Implementar y validar la cuantificación. 5. Incorporar conformidad y explicabilidad. 6. Evaluar el sistema integrado. 7. Proponer lineamientos de uso.	H1: no inferioridad en IoU. H2: caída $\geq$ 0,05 en leave-one-device-out, con recuperación $\geq$ 30 %. H3: MAE de ancho $\leq$ 1,5 px y error de calibración $\leq$ 5 %. H4: cobertura 90 % $\pm$ 3 pp (aleatoria) y $\geq$ 85 % (otro dispositivo).	Diseño: experimental computacional factorial, cinco semillas. Muestra: CCSS-DATA (670 imágenes, 4 cámaras) y conjunto de campo ($\geq$ 100). Instrumentos: Python, Ultralytics, OpenCV, fisurómetro. Análisis: bootstrap pareado, no inferioridad, Holm.

Anexo B. Estado del arte ampliado

Se seleccionaron 65 artículos de revista indexadas la Figura B.1 muestra la composición de la bibliografía.

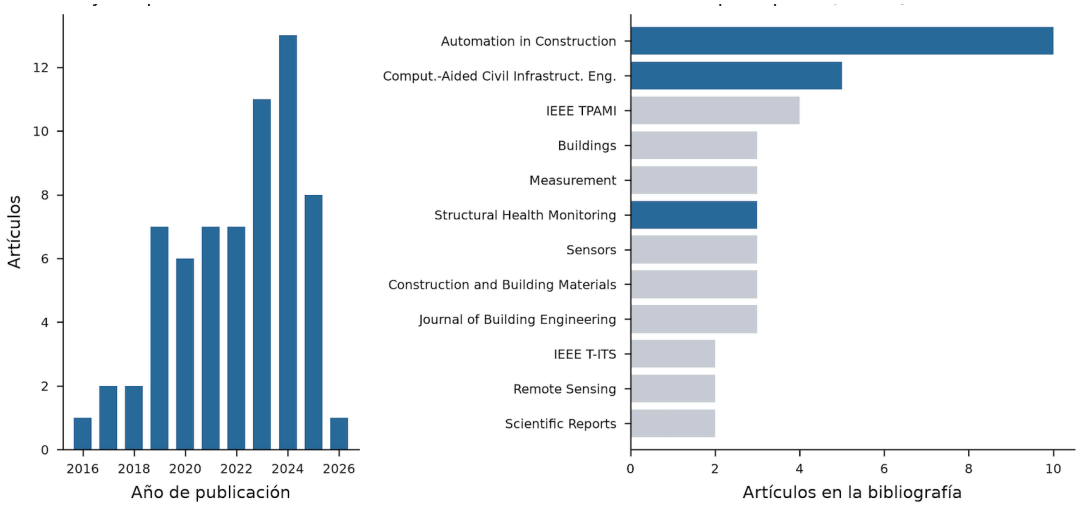


Figura B.1: Composición de la bibliografía por año y por revista (en azul, revistas con cuartil Q1).

B.1 Contexto de la inspección visual

La inspección de grietas mediante visión por computador es una línea ya consolidada del monitoreo de salud estructural: Dong y Catbas [2] sistematizan sus aplicaciones a nivel local (grietas, desprendimientos, delaminación, corrosión y pernos sueltos) y global, y destacan como ventajas el carácter sin contacto, el bajo costo y la mínima interferencia con la operación de la estructura, mientras que Spencer et al. [10] y, más recientemente, Zhuang et al. [25] revisan el avance de la inspección civil basada en imágenes y del aprendizaje profundo para grietas superficiales. El giro hacia redes convolucionales se asienta en Cha et al. [26], que detectan daño por grietas con CNN, y en Dung y Anh [27], que emplean una red completamente convolucional profunda para detectar grietas en concreto. Un punto que condiciona la novedad de cualquier propuesta actual es que la medición ya estaba en el título de los primeros trabajos a nivel de píxel [1]; por tanto, lo que sigue abierto no es "medir grietas" en abstracto, sino medirlas con trazabilidad métrica, comparabilidad entre dominios y una estimación explícita de incertidumbre.

B.2 Segmentación de grietas y datos

La segmentación de grietas ha pasado de métodos basados en bosques aleatorios estructurados [28] a arquitecturas jerárquicas profundas, entre ellas dos trabajos que comparten el nombre DeepCrack [29, 30], redes piramidales con refuerzo jerárquico [31], esquemas híbridos que añaden cuantificación sobre fondos complejos [32] y, en los últimos años, modelos con Transformers [33] y redes de doble ruta que combinan CNN y Transformer [34]. Cada una de estas propuestas se evalúa sobre conjuntos distintos, de modo que los datos públicos condicionan la comparación tanto como el modelo. SDNET2018 [35] ofrece imágenes de concreto anotadas para detección de grietas, pero a nivel de sub-imagen; RDD2022 [36] aporta 47 420 imágenes de seis países con más de 55 000 instancias de daño (grietas longitudinales, transversales, tipo piel de cocodrilo y baches) etiquetadas para detección y clasificación, y el mejor modelo del desafío asociado alcanzó un F1 de 76,9 %. Para segmentación de grietas en concreto con

máscaras a nivel de píxel, Shokri et al. [9] publican CCSS-DATA: 670 imágenes RGB de veredas de concreto con sus etiquetas semánticas, capturadas con cuatro cámaras distintas (308 con una Canon EOS M5, 124 con un Xiaomi Mi A1, 155 con una ZED estéreo y 83 con un Samsung Galaxy S7) y condiciones de luz variadas. Esa heterogeneidad de sensores convierte a CCSS-DATA en un banco natural para evaluar generalización entre dispositivos, aunque su dominio (veredas de concreto) no es el de una edificación y debe declararse como limitación de validez externa.

B.3 YOLO y detectores de instancia

La familia YOLO ofrece el compromiso velocidad–precisión que exige una inspección en campo o sobre dron. Las revisiones recuperadas recorren su evolución desde YOLOv1 hasta YOLOv8 y YOLO-NAS [3], su relación con la detección de defectos industriales y el despliegue en dispositivos de borde [17], su trayectoria de una década [37] y sus aplicaciones [38]. Como alternativas de instancia, Faster R-CNN [39] y Mask R-CNN [19] son los detectores de dos etapas de referencia, y YOLACT++ [18] la de segmentación de instancias en tiempo real. En esta revisión no se recuperó un artículo de revista Q1/Q2 que describa la arquitectura YOLO11 en sí: la implementación de referencia es software mantenido por Ultralytics, y la evidencia revisada por pares sobre YOLO11 aplicado a grietas es todavía escasa y muy reciente (2025–2026), lo cual obliga a que la tesis documente con precisión la versión, los hiperparámetros y las semillas, y a reportar la implementación como fuente técnica no indexada.

B.4 YOLO aplicado a grietas

La Tabla B.1 resume los resultados que los propios autores declaran en los resúmenes recuperados. La lectura útil no es el ranking, sino que las cifras no son comparables entre sí: cambian el conjunto de datos, la partición, la métrica (precisión, mAP50, mAP50-95, IoU) y hasta la tarea (detección con cajas frente a segmentación de instancias). Con esa salvedad, la evidencia apunta a tres patrones. Primero, las modificaciones ligeras de YOLOv8 y YOLO11 (módulos de atención, convoluciones Ghost o GSConv, cabezas de detección ligeras) elevan el mAP y reducen el costo computacional [6, 11]. Segundo, la segmentación de instancias con YOLO es viable en tiempo real para grietas de presas y puentes [4], y YOLO se emplea como localizador previo a un modelo de segmentación (Res-UNet o SAM) con IoU reportadas de 0,87 y 0,77 [7,12]. Tercero, en un estudio comparativo de versiones de YOLO para grietas en concreto, YOLOv10 fue la de mejor desempeño entre las evaluadas [5]; el resumen no indica si se incluyó YOLO11, de modo que la superioridad de esta última debe contrastarse, no suponerse. Otros trabajos extienden YOLO a túneles de metro con segmentación y medición [40], a grietas en obras de construcción con fusión de rasgos y atención [41], a detección en tiempo real con redes ligeras [42,43] y a pavimentos [44,45].

B.5 Cuantificación geométrica

Medir es lo que convierte una detección en evidencia técnica. Los enfoques recuperados estiman el ancho con momentos de Zernike combinados con aprendizaje profundo de doble escala [46], con calibración no lineal de píxeles [47], con visión por máquina desde dron [48], con un método híbrido en pavimento [49] y con cuantificación automática de longitud y ancho en asfalto [21]; en edificaciones, Minh Dang et al. [20] segmentan grietas en mampostería y miden su longitud real, Xu et al. [50] evalúan parámetros geométricos de grietas segmentadas en fachadas de concreto, y Chen et al. [51] proponen aprendizaje multitarea para segmentar y cuantificar en concreto armado. Solo dos de estos resúmenes estuvieron accesibles y ambos son informativos: Deng et al. [7] reportan una exactitud del 95 % en

Tabla B.1: Resultados declarados en los resúmenes de estudios YOLO para grietas y daño vial .

Estudio	Modelo	Tarea	Datos	Resultado declarado
[4]	LCA-YOLOv8-Seg	Segmentación de instancias (presas y puentes)	n.d. en el resumen	Precisión 0,945 a 129 FPS
[11]	YOLOv8-CD (YOLOv8 + LSKA, Ghost, GSConv)	Detección	RDD2022 y Wall Crack	mAP50 +15,2 % y +12,3 %; mAP50-95 +22,7 % y +17,2 %; 88 FPS
[5]	Varias versiones de YOLO (transferencia)	Detección	Conjuntos de concreto	YOLOv10: mAP 74,52 % a 19,5 ms por imagen
[6]	YOLO11-BD (YOLO11 modificado)	Detección	Grietas de puentes	mAP50 +3,1 %, mAP50-95 +4,8 %; GFLOPs −19,05 %; >500 FPS
[12]	YOLOv11 mejorado + SAM	Segmentación en dos etapas	n.d. en el resumen	IoU 0,77 (exactitud 95,98 %); IoU 0,64 con iluminación no uniforme
[7]	YOLOv5 + Res-UNet + cuantificación	Detección, segmentación y medición	Conjunto propio con ruido ambiental	mAP 91 %; IoU 87 %; RMSE de ancho 2,1 px
[44]	YOLOv8-PD (YOLOv8n modificado)	Detección de daño vial	RDD2022	+1,4 pp de mAP; 2,3 M parámetros y 6,1 GFLOPs

longitud y un error cuadrático medio de 2,1 píxeles en ancho, y Xu et al. [52] estiman longitud y espesor dentro de cada caja detectada, con un aumento del 29,2 % en mAP gracias a datos sintéticos para grietas de presas. En ambos casos el error se expresa en píxeles o no se reporta frente a una referencia física, y ninguno propaga incertidumbre a la medida. Para los demás estudios de la Tabla B.2 solo se dispuso del título, por lo que confirmar este patrón exige leer su texto completo.

Tabla B.2: Estudios de cuantificación de grietas y evidencia de error disponible en los resúmenes.

Estudio	Qué se cuantifica	Dominio	Error declarado
[46]	Ancho (Zernike + doble escala)	n.d.	No disponible
[47]	Ancho con calibración no lineal de píxeles	n.d.	No disponible
[48]	Ancho desde dron en puentes	Puentes	No disponible
[49]	Ancho, método híbrido	Pavimento	No disponible
[21]	Longitud y ancho	Asfalto	No disponible
[20]	Longitud real	Mampostería	No disponible
[50]	Parámetros geométricos	Fachada de concreto	No disponible
[51]	Segmentación y cuantificación multitarea	Concreto armado	No disponible
[7]	Longitud y ancho	Carreteras	Longitud 95 %; ancho RMSE 2,1 px
[52]	Longitud y espesor por caja	Presas	Error no reportado en el resumen

B.6 Edificaciones y contexto forense

En edificaciones, el problema cambia de naturaleza: las superficies son fachadas, muros de albañilería o elementos de patrimonio, con texturas, juntas y manchas que imitan grietas. Chen et al. [53] segmentan grietas en imágenes de fachada tomadas a corta distancia; Katsigiannis et al. [54] estudian la detección de grietas en fachadas de mampostería con pocos datos y transferencia de aprendizaje; Hacıefendioğlu et al. [55] trabajan con imágenes de celular de edificios históricos y encuentran que su modelo CAM-K-SEG es adecuado para localizar el objeto, mientras que U-Net resulta mejor para segmentar el área de la grieta; y Yiğit y Uysal [56] combinan fotogrametría con dron y detección automática de grietas en edificios patrimoniales. Perez et al. [57] ya habían planteado detectar y localizar defectos de edificación

(moho, deterioro, manchas) con una CNN y mapas de activación de clase, y [58] detectan grietas de edificios con aprendizaje profundo. El eslabón más cercano a lo forense es el reconocimiento de patrones de agrietamiento para evaluar la condición de estructuras de concreto [15]: asociar el patrón (orientación, ramificación, distribución) con una hipótesis de causa es lo que distingue una inspección forense de un simple conteo de grietas, y es un terreno poco explorado en los trabajos recuperados. Fuera de la edificación, el flujo de inspección con dron de Ayele et al. [59] encadena captura de imágenes, un modelo 3D que deja un registro permanente de la geometría del elemento y análisis de daño con aprendizaje profundo, y ofrece un precedente para vincular cada medida con su ubicación en la estructura.

B.7 Generalización y datos escasos

La generalización es el punto débil de buena parte del campo. La adaptación de dominio no supervisada [13] y los métodos que cierran brechas de dominio y de resolución en pavimento desde dron [14] abordan explícitamente el cambio de sensor y de condiciones; la revisión de generalización de dominio [24] ofrece el marco para tratarlo sin acceso al dominio objetivo. Frente a la escasez de anotaciones se han propuesto datos sintéticos [52], aprendizaje semisupervisado [60] y transferencia con pocos datos [54]; el desbalance extremo entre píxeles de grieta y fondo se aborda con la elección de la función de pérdida [61]. Los modelos de fundación abren otra vía: el ajuste fino de un modelo de visión [62], la adaptación de SAM con LoRA evaluada en ocho conjuntos de grietas [63] y el uso de YOLOv11 como generador de indicaciones para SAM [12], que reporta una IoU de 0,77 en su configuración general y de 0,64 bajo iluminación no uniforme con su estrategia de reingreso de máscara. Esa diferencia sugiere que la iluminación es una variable interviniente que debe controlarse y reportarse.

B.8 Incertidumbre y explicabilidad

Una decisión forense necesita saber cuánto confiar en cada medida. Sajedi y Liang [64] incorporan incertidumbre al monitoreo estructural con visión, y Zhang et al. [65] usan incertidumbre para seleccionar datos de entrenamiento y predicciones fiables en segmentación de grietas con datos limitados. Las revisiones de incertidumbre en redes profundas [22, 23] ordenan las técnicas disponibles, y Gawlikowski et al. [22] separan la incertidumbre del modelo (reducible) de la de los datos (irreducible); la predicción conforme [8] aporta una vía agnóstica al modelo: genera intervalos o conjuntos con garantía de cobertura sin supuestos distribucionales, aplicable a cualquier red preentrenada. Para explicabilidad, Grad-CAM [16] permite auditar visualmente qué región sustenta una detección, un requisito natural en un informe pericial. En los trabajos recuperados no se identificó la combinación de segmentación de grietas, medición de ancho en unidades físicas y cobertura conforme sobre esa medición.

B.9 Brechas y justificación

Las brechas siguientes se derivan de la muestra recuperada y se formulan como oportunidades de investigación, no como afirmaciones de ausencia en toda la literatura.

B.10 Alcance y límites de la revisión

Las afirmaciones se limitan a lo que el título o el resumen sustentan; la lectura de texto completo de los estudios centrales queda como tarea de la fase de revisión sistemática de la tesis.

Tabla B.3: Brechas identificadas en la literatura.

Brecha	**Descripción**	**Sustento**
B1	Escasa aplicación de YOLO11 en grietas	Los estudios YOLO11 recuperados proponen modificaciones arquitectónicas y se reportan frente a sus propias líneas base [6, 12]; no se encontró un protocolo que compare YOLOv8, YOLOv10 y YOLO11 con particiones fijas, semillas múltiples y pruebas estadísticas, y el único estudio comparativo recuperado favorece a YOLOv10 [5].
B2	Resultados no comparables	Las métricas y los conjuntos varían entre trabajos (Tabla B.1), por lo que ningún ranking es defendible sin un protocolo común.
B3	Generalización entre sensores y condiciones de luz	Los métodos de dominio se prueban sobre todo en pavimento [13, 14]; la diferencia de IoU entre iluminación general y no uniforme [12] y la heterogeneidad de cámaras de CCSS-DATA [9] justifican una evaluación dejando un dispositivo fuera (leave-one-device-out) con YOLO-seg.
B4	Medición en unidades físicas con incertidumbre	Los errores se reportan en píxeles [7] y la incertidumbre no se propaga a la medida; la predicción conforme [8] no se encontró aplicada al ancho de grietas en la muestra.
B5	Del dato al informe forense	El reconocimiento de patrones de agrietamiento [15] es el único antecedente cercano a diagnóstico; falta un flujo que entregue ancho, longitud, orientación, mapa de calor explicable y banda de incertidumbre por grieta en un informe trazable.